Fundamentos Matemáticos de los Energy-Based Models y las Joint Embedding Architectures

Pedro Rivas Vega

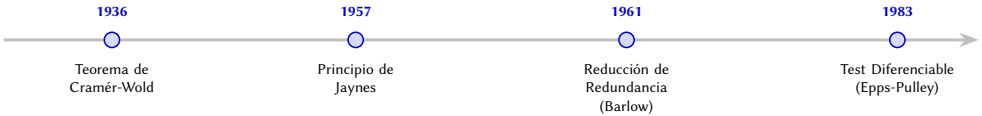
Grado en Matemáticas — Universidad de Sevilla

Julio 2026

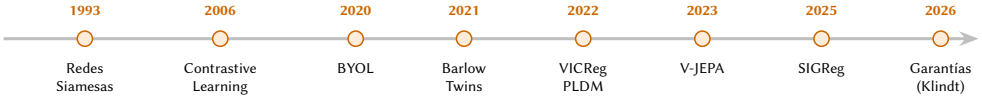


Cronología

Hitos Matemáticos Fundamentales



Evolución de las Joint Embedding Architectures (JEA)



Capítulo 1: Introducción y Paradigma JEA

El papel de la observación en el aprendizaje

La mayor parte del conocimiento se adquiere por observación pura de datos continuos (imágenes, vídeo), sin supervisión externa.
Las etiquetas humanas son un porcentaje mínimo de la información que procesa un agente inteligente.[1]
Los grandes modelos de lenguaje (LLM) han resuelto este aprendizaje autosupervisado (SSL) en dominios discretos. El objetivo de este trabajo es entender su traslación matemática al mundo continuo.

[1] LeCun 2022.

Paradigma Discriminativo y Generativo

Los dos enfoques clásicos del aprendizaje automático presentan limitaciones estructurales para capturar abstracciones en alta dimensión:

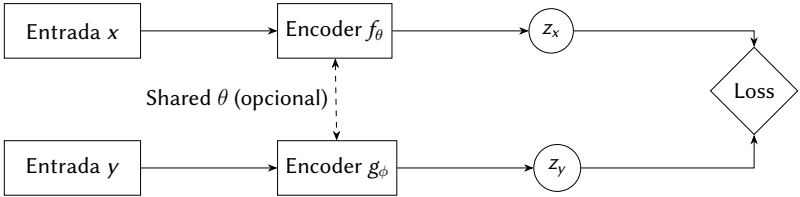
- **Modelos Discriminativos ($x \to y$):** Requieren un oráculo (etiquetas humanas) y descartan sistemáticamente información de la entrada.
- **Modelos Generativos ($x \to \hat{x}$):** Se ven obligados a invertir capacidad de red en reconstruir detalles estocásticos impredecibles a nivel de píxel (p.e. las hojas de un árbol moviéndose por el viento).

Joint Embedding Architectures (JEA)

Las JEA abordan el problema operando exclusivamente en un espacio latente abstracto $\mathcal{Z}$.

En lugar de generar o reconstruir la entrada, el modelo proyecta dos entradas relacionadas (x, y) a un espacio comprimido de características (z_x, z_y) y evalúa la similitud matemática entre sus representaciones.
Esto permite al modelo ignorar información irrelevante y retener solo el núcleo semántico.

Arquitectura Conceptual JEA



Capítulo 2: Modelos Basados en Energía

La Función de Energía (1/2)

Las JEA se formalizan mediante los Modelos Basados en Energía (EBM).[2] Un EBM asigna un valor escalar (energía) a cada configuración de variables (x, y), que cuantifica su grado de **incompatibilidad**:

$$E_\theta : \mathcal{X} \times \mathcal{Y} \to \mathbb{R}$$

En las arquitecturas Joint Embedding, la energía es típicamente la distancia euclídea al cuadrado en el espacio latente:

$$E_\theta(x, y) = \|f_\theta(x) - g_\phi(y)\|_2^2$$

[2] LeCun et al. 2006.

La Función de Energía (2/2)

A diferencia de los modelos probabilísticos, la integral de la superficie de energía sobre el espacio de variables no tiene por qué sumar uno.
La inferencia se reduce a un problema de optimización continuo, buscando el estado fundamental o de mínima energía:

$$y^* = \arg\min_{y \in \mathcal{Y}} E_\theta(x, y)$$

El Principio de Máxima Entropía de Jaynes (1/2)

Si se desea convertir la energía en una probabilidad, la formulación matemática correcta es la Medida de Boltzmann-Gibbs:

$$p_\theta(y|x) = \frac{e^{-\beta E_\theta(x,y)}}{Z(x;\theta)}$$

Edwin T. Jaynes (1957) demostró formalmente por qué esta es la elección canónica: es la única distribución probabilística que maximiza la Entropía de Shannon sujeta a un valor esperado de energía.[3]

[3] Jaynes 1957.

El Principio de Máxima Entropía de Jaynes (2/2)

El término $Z(x;\theta)$ es la función de partición. Se encarga de normalizar la distribución integrando (o sumando) la energía sobre todo el dominio posible de la variable y:

$$Z(x;\theta) = \int_{y\in\mathcal{Y}} e^{-\beta E_\theta(x,y)}\, dy$$

El cuello de botella probabilístico

El cálculo de la función de partición es la barrera infranqueable del aprendizaje continuo.

- **Dominio discreto (LLMs):** $\mathcal{Y}$ es un vocabulario finito (10^5 palabras). La integral se convierte en un sumatorio tratable, conocido como la función *Softmax*.
- **Dominio continuo (Visión):** $\mathcal{Y}$ es un espacio vectorial masivo (imágenes). La integral es intratable analítica y numéricamente.

Por este motivo, las JEA abandonan el marco probabilístico de Boltzmann y se ven forzadas a optimizar la energía escalar sin normalizar.

Capítulo 3: Redes Siamesas y el Colapso

Redes Siamesas (1993)

El abandono de la función de partición provoca el problema central de toda esta familia de modelos: el colapso de representación.
Bromley y LeCun (1993) propusieron la primera JEA, las Redes Siamesas, usando una única función de pérdida positiva que aproxima las representaciones de vistas relacionadas:[4]

$$\mathcal{L}_{\text{pos}}(W) = \mathbb{E}_{(x_1,x_2)\sim p_{\text{pos}}} \left[\|f_W(x_1) - f_W(x_2)\|_2^2 \right]$$

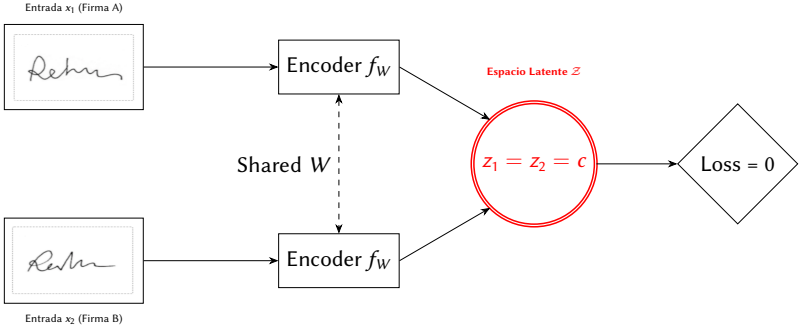
[4] Bromley et al. 1993.

El Colapso Constante como Mínimo Global

Teorema: Cualquier mapeo constante de la forma $f_{W^*}(x) = c$ para todo x, donde $c \in \mathbb{R}^d$ es un vector constante arbitrario, es un mínimo global absoluto de la pérdida $\mathcal{L}_{\text{pos}}(W)$.

Prueba directa: Por definición de norma euclídea: $\|f_W(x_1) - f_W(x_2)\|_2^2 \geq 0$. Si $f(x) = c$ para todo x, entonces la distancia es $\|c - c\|_2^2 = 0$. Como la cota inferior es 0, se trata de un mínimo global. El gradiente es exactamente cero, por lo que el estado de colapso es un atractor estable del que el optimizador no puede escapar.

Visualización del Colapso Siamés



Colapso Dimensional

Incluso si el modelo evade el colapso constante, es vulnerable al colapso dimensional: las características se contraen ocupando un subespacio lineal de rango muy inferior a la dimensión teórica d.

Dinámica de flujo de gradiente: El término $\|f(x_1) - f(x_2)\|_2^2$ somete a cada componente de los pesos a una fuerza de decaimiento continuo. Como demostraron Jing et al. (2022),[5] cada dimensión del espacio decae exponencialmente a una tasa que depende de la varianza en esa dirección.

[5] Jing et al. 2022.

Capítulo 4: Contrastive Learning

Pérdida Contrastiva con Margen (1/2)

La primera solución matemática al colapso fue la de Hadsell, Chopra y LeCun (2006).[6] Añadieron pares negativos (imágenes semánticamente distintas, $Y = 0$) para crear una fuerza de repulsión.

Fórmula de la Pérdida Contrastiva:

$$\mathcal{L}_{\text{cont}}(W) = \frac{1}{2}\,\mathbb{E}\left[Y\, d_W^2 + (1 - Y)\,\text{máx}(0, m - d_W)^2\right]$$

Donde d_W es la distancia euclídea y m es el margen de seguridad.

[6] Hadsell et al. 2006.

Pérdida Contrastiva con Margen (2/2)

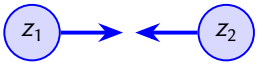
Al calcular el gradiente de un par negativo, si la distancia está dentro del margen m, la fuerza generada es:

$$\nabla_W \mathcal{L}_{\text{neg}} = -(m - d_W)\nabla_W d_W$$

Este signo negativo garantiza que el optimizador **empuje** las representaciones alejándolas mutuamente, lo que impide que las proyecciones colapsen en un único punto geométrico.

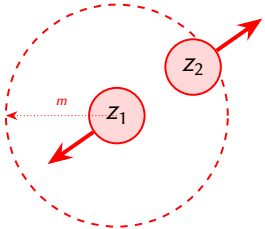
Dinámica de las Fuerzas Contrastivas

Pares Positivos ($Y = 1$)
Atracción tipo Muelle



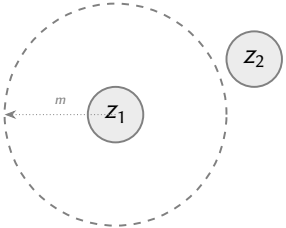
Atracción: F $\propto d_W$

Pares Negativos ($Y = 0$)
Repulsión activa ($d_W < m$)



Repulsión (F > 0**)**

Pares Negativos ($Y = 0$)
Reposo ($d_W \geq m$)



Reposo (F $= 0$**)**

El límite de la Epsilon-Red

Para que las pérdidas contrastivas prevengan el colapso dimensional, la repulsión debe aplicarse uniformente en todas las dimensiones de la hiperesfera $\mathbb{S}^{d-1}$.[7]

Por la teoría de Epsilon-Redes, el número mínimo de puntos (ejemplos negativos) necesarios para cubrir la superficie de una esfera dimensional con esferas de radio ε (margen) crece como:

$$N(\mathbb{S}^{d-1}, \varepsilon) \approx \left(\frac{1}{\varepsilon}\right)^d$$

Esta escala $\mathcal{O}(e^d)$ hace que el problema sea intratable en los grandes espacios del aprendizaje profundo.

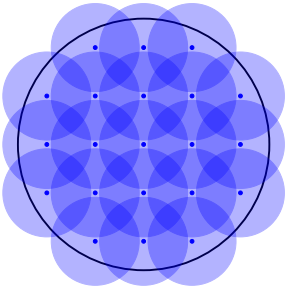
[7] Vershynin 2018.

Visualización de Zonas Ciegas

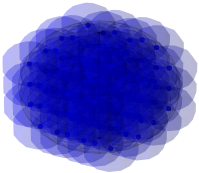
1D: $\mathcal{O}(1/\varepsilon)$



2D: $\mathcal{O}(1/\varepsilon^2)$



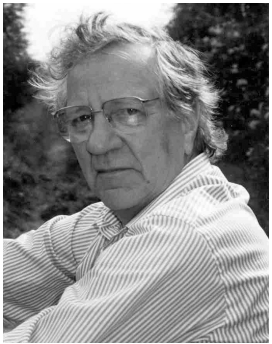
3D: $\mathcal{O}(1/\varepsilon^3)$



Capítulo 5: Revolución No Contrastiva

La Hipótesis de Barlow (1961)

Ante el límite exponencial de los negativos, se acude a la neurobiología.
Horace Barlow postuló que el cerebro decodifica las señales sensoriales minimizando la redundancia entre neuronas.[a]
El objetivo es que las representaciones finales sean mutuamente **independientes**, de forma que la red no malgaste capacidad de canal en transmitir información predecible por el contexto.



[a] Barlow 1961.

Información Mutua y Entropía

La independencia no puede medirse solo con la correlación lineal (que ignora dependencias no lineales). La métrica ideal es la **Información Mutua** de Shannon.[8]
La entropía individual $H(z_i)$ mide la información de una neurona. La información compartida por dos neuronas es:

$$I(z_i; z_j) = H(z_i) + H(z_j) - H(z_i, z_j)$$

Si son independientes, $I(z_i; z_j) = 0$.

[8] Shannon 1948.

Matriz de Información Mutua

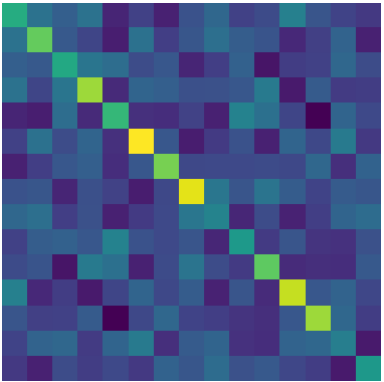
Para todo el vector latente, definimos la matriz $\mathcal{I}(Z) \in \mathbb{R}^{d \times d}$:

$$\mathcal{I}(Z)_{ij} = \begin{cases} H(z_i) & \text{si } i = j \\ I(z_i; z_j) & \text{si } i \neq j \end{cases}$$

El objetivo ideal de Barlow equivale a forzar que $\mathcal{I}(Z)$ sea una **matriz diagonal**: máxima retención de información propia (evita colapso) y nula información compartida (independencia).

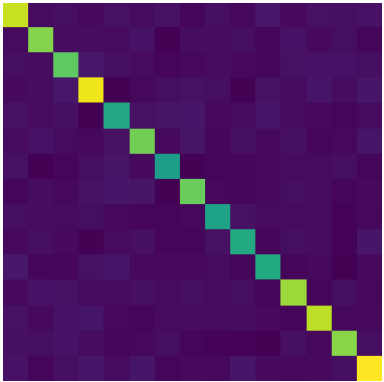
Diagonalizar la Información Mutua

Redundancia





Ideal de Barlow



El Problema de la Intratabilidad

Estimar $\mathcal{I}(Z)$ requiere conocer la función de densidad conjunta $p(Z)$ de los datos, lo cual es inobservable en problemas reales.
Además, su aproximación empírica sufre del mismo coste exponencial que el contrastive learning en dimensiones altas.

El Puente de Jaynes

La solución reside en una equivalencia fundamental. Si asumimos que las representaciones latentes Z siguen una distribución **Gaussiana Multivariante**, la Información Mutua depende únicamente del coeficiente de correlación de Pearson ρ_{ij}:

$$I(z_i; z_j) = -\frac{1}{2} \log(1 - \rho_{ij}^2)$$

Esta proposición indica que, bajo gaussianidad, la correlación lineal captura *todas* las dependencias estadísticas.

Equivalencia bajo Gaussianidad

Corolario: Sea $R \in \mathbb{R}^{d \times d}$ la matriz de correlación de Pearson. Bajo la hipótesis de normalidad, garantizar la independencia es equivalente a imponer la decorrelación lineal:

$$\mathcal{I}(Z) \text{ es diagonal} \iff R = I_d$$

Demostración: Para $i \neq j$, queremos $I(z_i; z_j) = 0$.

$$-\frac{1}{2}\log(1 - \rho_{ij}^2) = 0 \iff 1 - \rho_{ij}^2 = 1 \iff \rho_{ij} = 0$$

Como la diagonal de R es siempre 1, la condición equivale a $R = I_d$.

Construcción en Barlow Twins

Barlow Twins (2021) implementa este puente. Se generan dos vistas x_1, x_2, y se extraen los batches $Z^A, Z^B \in \mathbb{R}^{N \times d}$.[9]
Primero, se **centran en media** las columnas a lo largo del batch:

$$z_k^{A,(i)} \leftarrow z_k^{A,(i)} - \frac{1}{N} \sum_{m=1}^{N} z_k^{A,(m)}$$

Esto garantiza que se evalúe la verdadera covarianza, sin estar dominada por la magnitud de las medias.

[9] Zbontar et al. 2021.

Matriz de Correlación Cruzada Empírica

Se define la matriz empírica $C \in \mathbb{R}^{d \times d}$ calculando la similitud coseno entre las columnas de ambas vistas:

$$C_{kl} = \frac{\langle \mathbf{z}_k^A, \mathbf{z}_l^B \rangle}{\|\mathbf{z}_k^A\|_2 \, \|\mathbf{z}_l^B\|_2} = \frac{\sum_{i=1}^{N} z_k^{A,(i)} z_l^{B,(i)}}{\sqrt{\sum_{i=1}^{N} (z_k^{A,(i)})^2} \sqrt{\sum_{i=1}^{N} (z_l^{B,(i)})^2}}$$

Por su normalización euclídea, $C_{kl} \in [-1, 1]$.

La Pérdida de Barlow Twins

La pérdida final penaliza la discrepancia de C respecto a la identidad I_d:

$$\mathcal{L}_{\mathcal{BT}} = \underbrace{\sum_k (1 - C_{kk})^2}_{\text{Invarianza}} + \lambda \underbrace{\sum_k \sum_{l \neq k} C_{kl}^2}_{\text{Redundancia}}$$

La diagonal acerca las representaciones de las dos ramas. Fuera de la diagonal, se fuerza la ortogonalidad entre características distintas.

Problemas de Barlow: Pérdida de Escala

Proposición: La matriz C es invariante ante cualquier reescalado $\alpha_j > 0$ de una dimensión $z_j \mapsto \alpha_j z_j$.
Consecuencia: Si la red colapsa una dimensión (su varianza tiende a cero), la normalización en el denominador cancela el efecto, devolviendo un valor óptimo $C_{jj} \approx 1$. $\mathcal{L}_{\mathcal{BT}}$ carece de sensibilidad para detectar dimensiones colapsadas que han dejado de ser informativas.

Problemas de Barlow: Acoplamiento

El uso de una matriz normalizada C condensa dos objetivos (invarianza y decorrelación) sobre el mismo denominador compartido.
Cualquier actualización de los pesos altera simultáneamente la diagonal y los términos fuera de ella, acoplando las dinámicas y volviendo al modelo altamente dependiente del hiperparámetro λ y del tamaño del batch.

De la Correlación a la Covarianza

Para solucionar esto, VICReg (2022) abandona C y utiliza la matriz de **covarianza empírica sin normalizar**:[10]

$$C = \begin{pmatrix} 1 & C_{12} & \cdots & C_{1d} \\ C_{21} & 1 & \cdots & C_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ C_{d1} & C_{d2} & \cdots & 1 \end{pmatrix} \quad \text{vs} \quad \Sigma_{\mathcal{Z}} = \begin{pmatrix} \sigma_1^2 & \Sigma_{12} & \cdots & \Sigma_{1d} \\ \Sigma_{21} & \sigma_2^2 & \cdots & \Sigma_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ \Sigma_{d1} & \Sigma_{d2} & \cdots & \sigma_d^2 \end{pmatrix}$$

A diferencia de C, la diagonal de $\Sigma_{\mathcal{Z}}$ retiene explícitamente las varianzas individuales $\sigma_j^2 = (\Sigma_{\mathcal{Z}})_{jj}$, por lo que $\Sigma_{\mathcal{Z}}$ contiene estrictamente más información.

[10] Bardes et al. 2022.

Desacoplamiento VICReg: Invarianza

En lugar de forzar $C_{kk} \to 1$, VICReg mide la invarianza directamente en el espacio de representaciones mediante el **Error Cuadrático Medio** (como en las redes siamesas originales):

$$\mathcal{L}_{\text{pos}}(Z^A, Z^B) = \frac{1}{N} \sum_{i=1}^{N} \|z^{A,(i)} - z^{B,(i)}\|_2^2$$

Al no estar normalizado, penaliza tanto las diferencias en dirección como en magnitud.

Desacoplamiento VICReg: Varianza

Para evitar el colapso dimensional ciego de Barlow Twins, VICReg impone una pérdida tipo *hinge* sobre cada varianza $\sigma_j(Z) = \sqrt{(\Sigma_Z)_{jj}}$:

$$\mathcal{L}_{\text{var}}(Z) = \frac{1}{d} \sum_{j=1}^{d} \max\left(0,\ \gamma - \sigma_j(Z)\right)$$

Si la desviación típica de una dimensión cae por debajo del umbral $\gamma = 1$, la pérdida inyecta un gradiente expansivo, actuando como un muro explícito contra el colapso.

Desacoplamiento VICReg: Covarianza

Finalmente, para reducir la redundancia, VICReg penaliza la suma de cuadrados de todos los términos fuera de la diagonal de $\Sigma_{\mathcal{Z}}$:

$$\mathcal{L}_{\text{cov}}(Z) = \frac{1}{d} \sum_{\substack{k,l=1 \\ k \neq l}}^{d} (\Sigma_{\mathcal{Z}})_{kl}^2$$

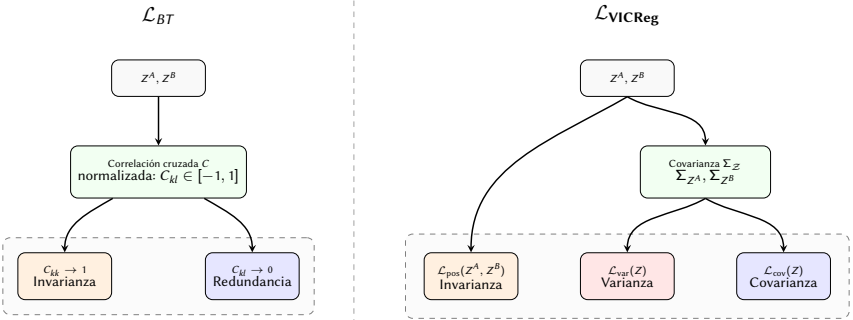
Como la equivalencia bajo gaussianidad garantiza que si la covarianza se anula, la información mutua también lo hace (Puente de Jaynes), esto satisface el Principio de Barlow.

La Función de Pérdida de VICReg

La pérdida total es una suma lineal con hiperparámetros independientes (μ_1, μ_2, μ_3) que no sufren de acoplamiento matricial:

$$\mathcal{L}_{\text{VICReg}} = \mu_1 \mathcal{L}_{\text{pos}} + \mu_2 \left(\mathcal{L}_{\text{var}}(Z^A) + \mathcal{L}_{\text{var}}(Z^B) \right) + \mu_3 \left(\mathcal{L}_{\text{cov}}(Z^A) + \mathcal{L}_{\text{cov}}(Z^B) \right)$$

Comparativa BT vs VICReg



Capítulo 6: World Models y Dimensión Temporal

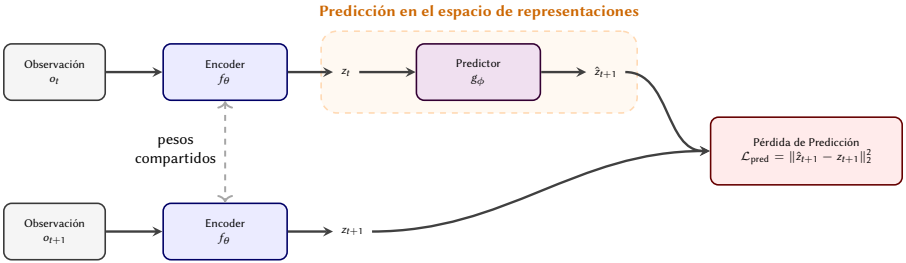
De JEA a Modelos de Mundo

La inclusión de la dimensión temporal exige construir agentes que puedan imaginar el estado futuro del entorno (planificar).
Se transita de una JEA estática a un World Model incorporando un **predictor** g_ϕ que aproxima la transición temporal puramente en el espacio $\mathcal{Z}$:

$$\hat{z}_{t+1} = g_\phi(z_t, a_t)$$

La asimetría es clave: la predicción ocurre en el tiempo posterior, pero la similitud se mide contra el encoder objetivo evaluado también en $t + 1$.

Arquitectura JEPA Temporal



Inestabilidad Temporal (PLDM)

PLDM (2022) es una extensión directa de VICReg al dominio temporal para entrenar World Models.[11]

Para evitar el colapso, su función de pérdida expande los términos de varianza y covarianza al eje temporal, sumando un total de 7 términos:

$$\mathcal{L}_{\text{PLDM}} = \mathcal{L}_{\text{pred}} + \alpha\mathcal{L}_{\text{var}} + \beta\mathcal{L}_{\text{cov}} + \gamma\mathcal{L}_{\text{time-sim}} + \zeta\mathcal{L}_{\text{time-var}} + \nu\mathcal{L}_{\text{time-cov}} + \mu\mathcal{L}_{\text{IDM}}$$

[11] Sobal et al. 2022.

V-JEPA y Heurísticas (1/2)

Para esquivar la intratabilidad matricial de PLDM, V-JEPA (2023) retira la regularización explícita y modifica la **arquitectura**.[12]
Introduce la **Media Móvil Exponencial (EMA)** para actualizar los pesos del encoder objetivo $\bar{\theta}$ a partir de los del encoder online θ:

$$\bar{\theta} \leftarrow \tau\bar{\theta} + (1 - \tau)\theta$$

Esto convierte a los estados futuros en blancos asimétricos que cambian despacio.

[12] Assran et al. 2023.

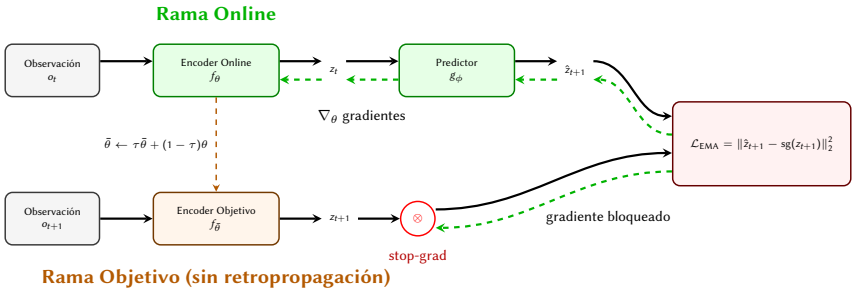
V-JEPA y Heurísticas (2/2)

Junto con EMA, emplea un **Stop-Gradient** para bloquear la retropropagación por el árbol de cálculo inferior. La pérdida asimétrica es:

$$\mathcal{L}_{\text{EMA}} = \|\hat{z}_{t+1} - \text{sg}(z_{t+1})\|_2^2$$

Estas heurísticas funcionan empíricamente rompiendo la simetría paramétrica, pero carecen de una interpretación estadística garantizada para el volumen latente.

V-JEPA y el bloqueo del objetivo



Capítulo 7: SIGReg y el cierre formal

Reformulación del Principio de Barlow

Hasta ahora los métodos asumían la normalidad para que el Puente de Jaynes garantizara independencia al decorrelacionar.
La solución definitiva es **forzar directamente** que el espacio siga una Gaussiana Isótropa: $Z \sim \mathcal{N}(\vec{0}, I_d)$.
Su función de densidad conjunta se factoriza analíticamente:

$$p(z) = \frac{1}{(2\pi)^{d/2}} \exp\left(-\frac{1}{2}\sum_i z_i^2\right) = \prod_i p(z_i)$$

Esta factorización exacta de las densidades marginales **es la definición misma de independencia estadística**. Forzar normalidad isótropa logra por definición el objetivo de Barlow.

Teorema de Cramér-Wold (1/2)

Comprobar normalidad multivariante en dimensión d es intratable.
El Teorema de Cramér-Wold (1936) demuestra que una distribución de probabilidad en $\mathbb{R}^d$ queda unívocamente determinada por la familia de todas sus proyecciones a subespacios de dimensión uno.
Es decir, la distribución multivariada se reduce a una colección infinita de distribuciones univariantes.[13]

[13] Balestriero y LeCun 2025.

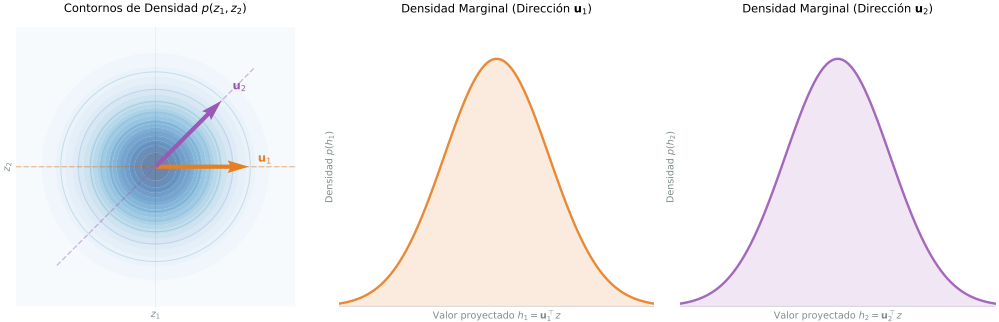
Teorema de Cramér-Wold (2/2)

En la práctica, SIGReg mapea un lote de embeddings $Z \in \mathbb{R}^{B \times d}$ proyectándolo contra direcciones aleatorias $\mathbf{u}^{(m)}$ muestreadas en la esfera unitaria:

$$\mathbf{h}^{(m)} = Z\mathbf{u}^{(m)} \in \mathbb{R}^{B}$$

Forzar que $\mathbf{h}^{(m)} \sim \mathcal{N}(0, 1)$ para toda proyección garantiza por Cramér-Wold que el espacio completo converge a la distribución gaussiana requerida.

Cramér-Wold Visualizado



El Test de Epps-Pulley Diferenciable (1/2)

Los test clásicos univariantes (e.g. Kolmogorov-Smirnov) emplean la operación de supremo (sup) sobre la distribución acumulada empírica. Esto no es diferenciable y rompe el algoritmo de *backpropagation*.
Epps y Pulley (1983) formulan un test utilizando la Distancia L^2 sobre la **Función Característica** poblacional (la transformada de Fourier de la distribución).[14]

[14] Epps y Pulley 1983.

El Test de Epps-Pulley Diferenciable (2/2)

El estadístico resultante evalúa sobre la proyección muestral $h_1 \dots h_n$:

$$T_{EP}(\mathbf{h}) = 1 + \frac{\sqrt{2}}{n^2} \sum_{j,k} e^{-\frac{(h_j - h_k)^2}{4}} - \frac{4}{\sqrt{3}\, n} \sum_{j} e^{-\frac{h_j^2}{6}}$$

Esta formulación analítica exacta es una suma finita de funciones exponenciales, lo que la hace de clase $\mathcal{C}^\infty$ e **infinitamente diferenciable** respecto de las observaciones, integrándose a la perfección en redes neuronales.

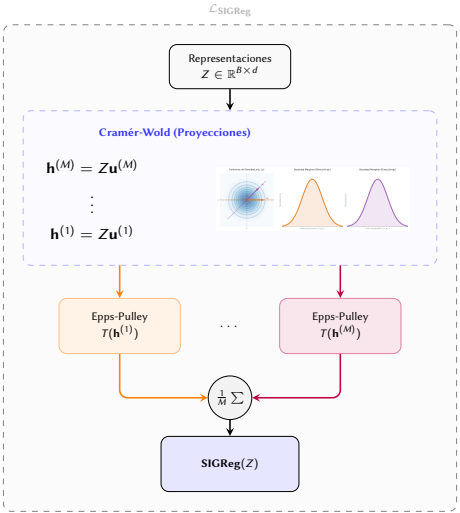
SIGReg y LeWorldModel

La pérdida total que rige el entrenamiento del LeWorldModel condensa toda la corrección:

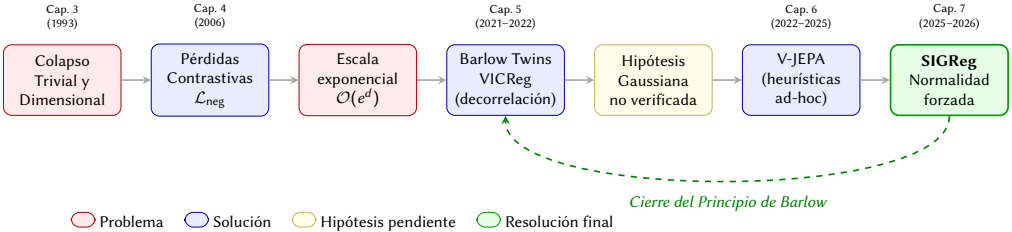
$$\mathcal{L}_{\text{LeWM}} = \mathcal{L}_{\text{pred}} + \lambda \, \text{SIGReg}(Z)$$

donde $\text{SIGReg}(Z) = \frac{1}{M} \sum_m T_{EP}(Z\mathbf{u}^{(m)})$.
Esta formulación elegante reemplaza 7 términos en PLDM por solo 1 término probabilístico exacto, eliminando gradientes contradictorios y forzando explícitamente el Puente de Jaynes sin negativos.

SIGReg en LeWorldModel



El Arco Narrativo y Cierre de Barlow



Conclusiones y Líneas Futuras

Conclusiones (1/2)

1. **EBMs como marco unificador:** formalizan la compatibilidad sin requerir probabilidad. La constante de normalización obliga a operar de manera no paramétrica.
2. **El colapso como hilo conductor:** el aprendizaje JEA es una sucesión continua de soluciones analíticas y topológicas para evadir la degeneración latente.

Conclusiones (2/2)

3. **El cierre de Barlow:** SIGReg impone explícitamente que Z asuma una distribución normal isótropa, independizando dimensiones sin requerir heurísticas.
4. **Recuperación Garantizada:** Klindt et al. (2026) demostraron formalmente que la gaussiana isótropa de SIGReg es la única formulación que asegura la recuperación lineal (ICA) de las verdaderas variables físicas del entorno subyacente.[15]

[15] Klindt et al. 2026.

Líneas futuras

H-JEPA y Predicción Jerárquica: Los modelos temporalmente planos (1-step) fallan en horizontes largos de planificación (Control Robótico). Integrar SIGReg en estructuras jerárquicas con abstracción temporal multinivel es investigación de frontera.

Sistemas dinámicos observacionales complejos: Llevar estas arquitecturas más allá de la robótica visual a tareas analíticas con simuladores latentes: estimación de modelos fluidodinámicos, diseño biomédico o ingeniería de materiales.

Gracias por su atención

"Las redes convolucionales de LeCun, formuladas en los ochenta, esperaron casi cuatro décadas hasta que la escala computacional les dio la razón. ¿Será el destino de las JEA repetir esa trayectoria?"

Pedro Rivas Vega
Grado en Matemáticas - Universidad de Sevilla
Julio 2026

Referencias I

- Assran, Mahmoud et al. (2023). «Self-supervised learning from images with a joint-embedding predictive architecture». En: *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, págs. 15619-15629.
- Balestriero, Randall y Yann LeCun (2025). «Lejepa: Provable and scalable self-supervised learning without the heuristics». En: *arXiv preprint arXiv:2511.08544*.
- Bardes, Adrien, Jean Ponce y Yann LeCun (2022). «Vicreg: Variance-invariance-covariance regularization for self-supervised learning». En: *International Conference on Learning Representations (ICLR)*.
- Barlow, Horace B (1961). «Possible principles underlying the transformations of sensory messages». En: *Sensory Communication*, págs. 217-234.

Referencias II

- Bromley, Jane et al. (1993). «Signature verification using a "Siamese" time delay neural network». En: *Advances in Neural Information Processing Systems*. Vol. 6.
- Cramér, Harald y Herman Wold (1936). «Some theorems on distribution functions». En: *Journal of the London Mathematical Society* 1.4, págs. 290-294.
- Epps, Thomas W y Lawrence B Pulley (1983). «A test for normality based on the empirical characteristic function». En: *Biometrika* 70.3, págs. 723-726.
- Goodfellow, Ian, Yoshua Bengio y Aaron Courville (2016). *Deep Learning*. `http://www.deeplearningbook.org`. MIT Press.
- Grill, Jean-Bastien et al. (2020). «Bootstrap your own latent: A new approach to self-supervised learning». En: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 33, págs. 21271-21284.

Referencias III

- Hadsell, Raia, Sumit Chopra y Yann LeCun (2006). «Dimensionality reduction by learning an invariant mapping». En: *IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR)*. Vol. 2, págs. 1735-1742.
- Jaynes, Edwin T. (1957). «Information theory and statistical mechanics». En: *Physical Review* 106.4, págs. 620-630.
- Jing, Li et al. (2022). «Understanding dimensional collapse in contrastive self-supervised learning». En: *International Conference on Learning Representations (ICLR)*.
- Klindt, David, Yann LeCun y Randall Balestriero (2026). «When Does LeJEPA Learn a World Model?» En: *arXiv preprint arXiv:2605.26379*.
- LeCun, Yann (2022). «A path towards autonomous machine intelligence version 0.9. 2». En: *Open Review*.

Referencias IV

- LeCun, Yann et al. (2006). «A tutorial on energy-based learning». En: *Predicting Structured Data*. Ed. por G. Bakir et al. MIT Press.
- Shannon, Claude E. (1948). «A mathematical theory of communication». En: *Bell System Technical Journal* 27.3, págs. 379-423.
- Sobal, Vlad et al. (2022). «Joint embedding predictive architectures focus on slow features». En: *arXiv preprint arXiv:2211.10831*.
- Sobal, Vlad et al. (2025). «Learning from Reward-Free Offline Data: A Case for Planning with Latent Dynamics Models». En: *arXiv preprint arXiv:2502.14819*.
- Vershynin, Roman (2018). *High-dimensional probability: An introduction with applications in data science*. Vol. 47. Cambridge university press.
- Yu, Tianhe et al. (2020). «Gradient Surgery for Multi-Task Learning». En: *arXiv preprint arXiv:2001.06782*.

Referencias V



Zbontar, Jure et al. (2021). «Barlow twins: Self-supervised learning via redundancy reduction». En: *International Conference on Machine Learning (ICML)*, págs. 12310-12320.